

生成的敵対ネットを用いた高周波データのトック市場予測

興友周¹、ジソンパン、¹ ガイウ胡、¹ シキタン、¹ とチェン趙^{1,2}

もっと表示する

アカデミック・エディター: 銭張

2017 年 11 月 06 日受賞

改訂 2018 年 1 月 21 日

受け入れ 2018 年 2 月 13 日

公開 15 Apr 2018

抽象

株価予測は、株式取引の効果的な戦略の発展に貢献する金融界の重要な課題です。本稿では、高周波株式市場を予測するための敵対的訓練のために、長期記憶(LSTM)と畳み込みニューラルネットワーク(CNN)を用いた一般的な枠組みを提案する。このモデルは、複雑な金融理論調査と困難なテクニカル分析を避けるために、取引ソフトウェアによって提供される一般に入手可能なインデックスを入力として取り入れ、非金融専門分野の通常のトレーダーに利便性を提供します。我々の調査は、実際のトレーダーの取引モードをシミュレートし、ローリングパーティショントレーニングセットとテストセットの方法を使用して、予測パフォーマンスに対するモデル更新サイクルの影響を分析します。広範な実験は、我々の提案されたアプローチが効果的に株価方向予測精度を向上させ、予測誤差を減らすことができることを示しています。

1. はじめに

合理的に正確な予測は、高い財務上の利益をもたらす、市場リスクに対してヘッジする可能性があるため、株価の予測は金融界の重要な目的である[1-3]。インターネットとコンピューティング技術の急速な成長に伴い、株式市場での運用の頻度は数秒(4、5)に増加しました。2009年からBM&F Bovespa(ブラジル証券取引所)は高頻度で働き、高周波事業の数は2009年の2.5%から2013年には36.5%に増加しました。オルドリッジとクラウチウ[6]は、2016年に平均で高頻度取引が株式の取引量の10%から40%、外国為替および商品の量の10%から15%を開始したと推定しています。これらのパーセンテージは、高頻度の株式市場が世界的な傾向であることを示唆しています。

ほとんどの場合、予測結果は、実際の価格と予測値の間の予測誤差（主にRMSE(平方平方誤差)またはRMSRE(平方平方根の平均誤差))の2つの側面から評価されます。2つ目は、上向きと下向きの動きが意思決定にとって本当に重要であるため、価格系列の方向の正しい予測の割合を意味する方向予測精度です。予測パフォーマンスのわずかな改善でも、非常に有益なことができます[7,8]。

しかし、市場の複雑さと混沌としたダイナミクスと、多くの非定常的な確率変数[9]を伴うため、株価の予測は容易な作業ではありません。さまざまな分野の研究者が金融時系列の歴史的パターンを研究し、株価を予測するための様々な方法を提案してきました。これらの方法の大半は、有望なパフォーマンスを達成するために、入力変数の慎重な選択、専門的な財務知識を持つ予測モデルの確立、アービトラージ分析のための様々な統計手法の採用を必要とするため、財務分野外の人々が株価を予測するためにこれらの方法を使用することが困難になります[10-12]。

生成的敵対ネットワーク(GAN)は、同時に訓練された2つのネットワークを使用してランダムノイズから画像パッチが生成される Goodfellow ららによって導入されました。具体的には、GANでは、識別ネットは、特定のデータインスタンスが実際のものかどうかを区別することを学習し、生成ネットは高品質のデータを生成することによって混乱することを学習します。このアプローチは、画像のインペインティング、セマンティックセグメンテーション、ビデオ予測[14-16]など、幅広い分野にうまく適用されていますが、私たちが知る限りでは株式予測には使用されていません。

この作業では、基本的な技術インデックスデータを入力変数として使用し、取引ソフトウェアから直接取得できるため、財務分野外の人々が当社の方法を通じて株価を簡単に予測できます。この研究では、予測誤差損失と方向予測損失を導入し、これらの損失を組み合わせることで満足いく予測結果を生成するために生成的敵対的トレーニング[13]がうまく採用される可能性があることを示し、この予測アーキテクチャ GAN-FD(予測誤差損失と方向予測損失を最小限に抑える GAN)と呼んでいます。実際の取引の実践に適合するために、この作業は、生データのトレーニングセットとテストセットに対するローリングセグメンテーションを行い、実験セクションで詳細に説明します。

全体として、私たちの主な貢献は、(1)株式市場への敵対的訓練の最初の適用を構成する価格予測を目的とした生成的敵対ネットワークを適応させ、広範な実験は、我々の予測モデルが顕著な結果を達成できることを示し、(2)我々は、株式予測パフォーマンスにモデルパラメータサイクルの効果を調査するために、生データのトレーニングセットとテストセットにローリングセグメンテーションを行うことを示しています実験結果によると、モデル更新サイクルが小さくなると予測パフォーマンスが向上します。

この論文の残りの部分では、金融市場予測にアルゴリズムが使用されている文献のレビューから始めます。次に、問題を策定し、一般的な敵対的ネットワークフレームワークを提案します。さらに、実験セクションでは、提案されたモデルを用いて実験分析を行い、得られた結果と古典的予測モデルで得られた結果を比較した。最後に、結論と可能な拡張について説明します。

2. 関連作業

このセクションでは、株式市場予測法と生成的な敵対ネットワークからの関連作業について紹介します。

2.1. 株式市場予測法

この分野で開発された研究によれば、株式市場予測問題を解決するために用いられる技術を二重に分類できる。

関連作業の最初のカテゴリは、予測のための古典的な計量経済学モデルを含む計量モデルです。

一般的な方法は、自己回帰法(AR)、移動平均モデル(MA)、自己回帰移動平均モデル(ARMA)、および自己回帰統合移動平均(ARIMA)[17-19]です。大まかに言えば、これらのモデルは、最後のいくつかの信号と独立したノイズ項の騒々しい線形の組み合わせとして、各新しい信号を取ります。しかし、そのほとんどはノイズ用語(i.i.d.仮定、-分布など)と損失関数に関していくつかの強い仮定に依存していますが、実際の財務データはこれらの仮定を完全には満たしていない可能性があります。条件付分散に対する一般化された自己回帰条件付き異種(GARCH)モデルを導入することにより、ペレグリーニら[20]は、金融時系列の予測に ARIMA-GARCH モデルを適用する。

2 番目のカテゴリは、ソフト コンピューティング ベースのモデルです。ソフトコンピューティングは、生物学的プロセスを模倣する人工知能をカバーする用語です。これらの手法には、人工ニューラルネットワーク(ANN)[21,22]、ファジィ論理(FL)[23]、サポートベクターマシン(SVM)[24,25]、粒子群最適化(PSO)[26]、その他多くが含まれる。多くの著者は、オプション価格モデル[27、28]のランダム性と共にあいまいさに対処しようとしていました。カールソンとフラー[29]は、ファジーリアルオプションを最初に研究し、タバネスワランら[30]は、ファジィ予測の優位性を示し、その後、金利、ボラティリティ、株価の初期値をあいまいにすることによって、ヨーロッパのコール価格のメンバーシップ関数を導き出しました。最近、ディープラーニングへの関心が復活し、その基本構造は多層ニューラルネットワークとして最もよく記述されています[31]。一部の文献では、高頻度金融時系列[32,33]の予測能力を向上させるために、ディープニューラルネットワークに基づいて様々なモデルを確立しています。深いニューラルネットワークがデータから抽象的な特徴を抽出する能力も魅力的である[12]は、予測変数の事前知識に頼らずに株式リターン時系列から情報を抽出し、韓国の株式市場からの高頻度データでテストするディープ機能学習ベースの株式市場予測モデルを適用した。Chen et al. [34] は、異なるビジネスセクター内の株式リターン間の依存構造を捉えるように特別に設計されたリンクを持つ、高周波予測用の二層ニューラルネットワークを提案した。過去のニュースイベントと株式市場の動きの関係を特定するためにディープラーニングを適用するいくつかの研究もあります[35-37]。

しかし、私たちの知る限りでは、これらの方法のほとんどは、関連する株式をエントリデータとして組み合わせたり、ディープニューラルネットワーク[34]の異なる層に異なるインデックスデータを入力したり、ニューステキストを入力として構造化表現に変換したり、入力変数に特定の

制限を課す専門知識を必要とします[36]。対照的に、当社の提案された予測モデルは、取引ソフトウェアが提供するデータを直接入力として使用し、一般投資家の障壁を低減します。

2.2. 生成的敵対ネットワーク

生成的敵対ネットワーク(GAN)は、敵対的なプロセスを介して生成モデルを推定するためのフレームワークであり、データ分布をキャプチャする生成モデルと、サンプルがトレーニングデータから来た確率を推定する判別モデルの2つのモデルを同時に訓練します。訓練の手順は、間違いを犯す確率を最大化することです。このフレームワークは、ミニマックスの2プレイヤーゲームに対応しています。任意の関数と D の空間には、トレーニングデータの分布を回復し、どこでも 0.5 に等しい独自のソリューションが存在します [13]。[13]では多層パーセプトロンによって定義されていますが、最近構築された研究の多くは、長期記憶(LSTM)[38]または畳み込みニューラルネットワーク(CNN)[39]に基づいて、さまざまな用途に対応しています。

LSTM は基本的なディープラーニング モデルであり、長期的な依存関係を学習できます。

LSTM 内部ユニットは、セル、入力ゲート、出力ゲート、および忘れゲートで構成されます。

LSTM の内部単位は、単純な学習された格子関数を使用して、状態が変更なしで伝播したり、更新されたり、リセットされたりできるように、非線形メカニズムで拡張された隠れ状態を備えています。LSTM は、自然言語のテキスト圧縮、手書き認識、電気負荷予測など、さまざまな問題に非常にうまく対応しています。

CNN は、視覚的な画像の分析にうまく適用された深い、フィードフォワード人工ニューラルネットワークのクラスです。CNN は、入力レイヤーと出力レイヤー、および複数の非表示レイヤーで構成されます。CNN の隠し層は、通常、畳み込みレイヤー、プーリング レイヤー、完全に接

続されたレイヤー、および正規化レイヤーで構成されます。また、画像やビデオの認識、推薦システム、自然言語処理など、多くのアプリケーションを持っています。

LSTM モデルを用いて株価を予測する文献はたくさんありますが、私たちの知る限りでは、この論文は GAN を採用して株価を予測する最初の論文です。実験部分(セクション [4.2](#))は、GAN-FC と LSTM の予測性能を比較します。

3. 高頻度データを用いる予測

このセクションでは、高頻度データによる株式市場予測のための生成的な敵対ネットワークフレームワークの詳細を明記します。

3.1. 問題文

高頻度取引環境下では、通常、高品質なワンステップ予測はアルゴリズムトレーダーにとって大きな関心事であり、リスク評価と管理のために市場メーカーに重要な情報を提供します。本稿では、過去の価格情報のみに基づいて、個々の株式や市場指数の一步先の価格変動を予測することを目指しています。私たちの問題は、次のように数学的に形式化することができます。

基本的な指標のセットを表し、時間の 1 分間隔で 1 つの株式の終値を示しましょう。ここで最大ラグの時間です。歴史的な基本的な指標情報と過去の終値を考えると、私たちの目標は、次の 1 分間の時間間隔の終値を予測することです。異なる [7、12、40] の効果を調べた文献がありますが、この作品では、各取引日が中国証券取引所に 242 分間隔で含まれているため、242 に設定しました。

3.2. 予測モデル

提案された GAN-FD モデルの深いアーキテクチャは図 [1](#) のように示されています。ストックデータは典型的な時系列であるため、入力データに基づいて出力を予測する生成モデルとして、時系列予測に広く適用される LSTM モデルを選択します。つまり、

図 1

GAN-FD アーキテクチャ。発電機は、予測に適用される LSTM に基づいて設立されています。判別子は、シーケンスが実際であるか予測されているかの確率を推定する目的で、CNN に基づいています。コンブ。は畳み込み層を意味し、FC FC は完全に接続された層の略称である。の構造と特定のアプリケーションに応じて調整することができます。

識別モデルは、CNN アーキテクチャに基づいており、シーケンスがデータセットから来ているか、生成モデルによって生成される可能性を推定するために、1 次元入力シーケンスに対して畳み込み演算を実行します。

なぜ敵対的損失を使用するのかの私たちの主な直感は、金融トレーダーの営業習慣をシミュレートできることです。経験豊富なトレーダーは通常、利用可能な指標データ(生成モデルの仕事)を通じて株価を予測し、差別的なモデルがそうであるように、以前の株価で自分の予測の正しい確率を判断します。

GAN-FD の構造と、GAN-FD の構造は特定の用途に応じて調整できることが注目に値し、本稿の実験部分は株式予測のための単純なフレームワーク(セクション [4.2](#))を提案しただけである。の構造を微調整し、予測パフォーマンスを向上させることができると信じるのは妥当です。

3.3. 敵対的訓練

ペアのトレーニング (,) は、以下に説明する 2 つの交互のステップで構成されます。わかりやすくするため、純粋な SGD (サイズ 1 のミニバッチ) を使用することを前提としていますが、サンプルの損失を合計してサイズのミニバッチにアルゴリズムを一般化することは難しいはありません。

トレーニング(データセットのサンプルにしましょう)。差別的なモデルを可能な限り「混乱」させるためには、生成モデルは予測を正しく区別しない意味での敵対的損失を減らすべきである。クラス 1 に分類し、クラス 0 に分類すると、敵対損失はシグモイドクロスエントロピー損失であり、次のように定義されています。

しかし、実際には、敵対的損失を最小限に抑えるだけでは、満足のいく予測を保証することはできません。に近づくことがなく、サンプルを「混乱」させる可能性があり、これらのサンプルを判別することを学び、他の「混乱」サンプルを生成するなど、そのサンプルを生成できると想像してください。この問題に対処するために、生成モデルは予測誤差損失を減らす必要があります。つまり、場所を失うか、。

さらに、前述のように、株価方向予測は取引にとって非常に重要なので、方向予測損失関数を定義します:ここで符号関数を表します。

これまでに定義されたこれらの損失をすべて異なるパラメータ、、および、で結合すると、最終的な損失が達成されます。

次に、固定の重みを維持しながら最小化するために、1 つの SGD 反復を実行します。

トレーニング(別のデータ サンプルにしましょう)。の役割は入力シーケンスが、または、 D の逆損失と等しいかどうかを判断することだけなので D 、固定の重みを維持しながら、目標損失を最小限に抑えるために 1 つの SGD ステップを実行します。

私たちは発電機と差別を反復的に訓練します。プロセス全体がアルゴリズム [1](#) に要約され、サイズ m のミニバッチが表示されます。

(1)学習率と パラメータを設定する

...;

(2)重みおよび b を初期化します。

(3)while 収束しない間に行う

(4)ジェネレータを更新する:

(5)新しいデータ サンプルを取得する (、

),..., (,)

(6)

(7)判別器を更新する:

(8)新しいデータ サンプルを取得する (、

),..., (,)

(9)

(10)終了中

アルゴリズム 1

トレーニングガン-FD。

4. 実験

4.1. データセット

次に、2016 年 1 月 1 日から 2016 年 12 月 31 日までの中国株式市場に基づく提案方法のパフォーマンスを評価します。完全に 244 取引日があり、毎日 59048 のタイムポイントに対応する 242 分間隔が含まれています。実験のために選択されたこれらの株式は 3 つの基準に準拠する必要があります:最初に、彼らは 300 の構成株式でなければなりません (*CSI 300* は上海と深セン証券取引所で取引された 300 株のパフォーマンスを複製するように設計された資本化加重株式市場指数です)。偶発的な出来事が価格に大きな影響をもたらし、予測結果に影響を与える場合、2016 年 1 月 1 日の終値は、高頻度取引所のボラティリティを確保するために 30 を超えています。この結果、サンプルに 42 個の在庫が残されており、これを表 [1](#) に示します。各株式の終値/分の方向の増加と減少方向の数も表 1 に示 [1](#) されており、その数は比較的近い。過去のデータは、ウィンド・インフォメーション社が作成したウィンド・ファイナンシャル・ターミナルから取得したもので、ウィンド・ファイナンシャル・ターミナルは <http://www.wind.com.cn> からダウンロードできます <http://www.wind.com.cn>。

表 1

サンプルストックと、その数の方向の増加と方向の減少。

株式市場の多くのファンドマネジャーや投資家は、一般的に、将来の市場動向のシグナルとして、テクニカル指標の一定の基準を受け入れ、使用します[12,41]。この研究は、ドメインの専門家と以前の研究のレビューによって特徴のサブセットとして 13 のテクニカル指標を選択します。つまり、各瞬間の入力データ(例えば)は、ほぼすべての取引ソフトウェアから直接得ることができ

る 13 の基本的な指標で構成されています。これらの基本指標は表 22 にリストされており、これらのパラメータは Wind Financial Terminal のデフォルト値を使用しています。前述のように、各瞬間の終値として定義されます。

表 2

予測のための基本的な指標。

関連記事のほとんどは、従来のデータパーティション分割方法を使用します。つまり、データセット全体が直接トレーニング セットとテスト セット [12, 22, 40, 42] に分割されます。しかし、株式市場の取引スタイルは頻繁に変化します。例えば、投資家はボラティリティの高い株式を好む場合があり、時にはテクノロジー株に投資する傾向があります。したがって、市場スタイルの変化に適応するために、モデルパラメータを定期的に更新する必要があります。実際の取引に近い実験を行うために、実験データのトレーニングセットとテストセットに対してローリングセグメンテーションを行います。図 2 に示すように、最初は最初にトレーニング セットとして最初の日を選択し、次の日はテスト セットの役割を果たします。実験の最初のラウンドの後、私たちは何日も時間枠をロールフォワードし、つまり、トレーニングセットとしてその日を選択し、テストセットとしてその日から日まで選択します。すべてのデータが実験されるまで繰り返します。つまり、これはモデル更新サイクルと見なされ、対応するトレーニングデータのサイズです。

図 2

トレーニングセットとテストセットでのローリングセグメンテーション。緑色のバーはデータセット全体を表し、青いバーはラウンド実験のトレーニングセットを表し、黄色のバーは対応するテストセットを表します。

4.2. ネットワークアーキテクチャ

LSTM ジェネレーターが予測の役割を担い、CNN 判別器よりも正確な値の計算を必要とすることを考えると、学習率を 0.0004 と 0.02 に設定します。LSTM セルには 121 の内部（隠し）単位が含まれ、パラメータは正規分布 に従って初期化されます。識別モデルのアーキテクチャを表 3 に示します。私たちは、によって重み付けされた GAN-FD を訓練します。

表 3

差別的モデルのネットワークアーキテクチャ

4.3. ベンチマーク手法

提案された手法のパフォーマンスを評価するために、比較のためのベースラインメソッドを3つ含めます。最初のモデルは、株式時系列の将来の価値を予測し、GARCH モデルは将来のボラティリティ [20] を予測する適合 ARIMA モデルである ARIMA -GARCH です。2 つ目は人工ニューラルネットワーク (ANN) です。パラメータ最適化方法とモデルアーキテクチャは [21] のように設定されていますが、入力レイヤーノードが 13 に変更され、ネットワークは 2 つのパターン (0 または 1) ではなく予測値を出力します。3 つ目は、サポートベクターマシン (SVM) です。RBF カーネルが使用され、パラメータが [25] のように設定されます。

また、いくつかの方法で GAN-FD モデルを検査します。GAN-F モデルでは、予測誤差損失を最小限に抑えるために GAN アーキテクチャを使用しています。GAN-D モデルでは、方向予測損失を最小限に抑えるために GAN アーキテクチャを使用しています。LSTM-FD モデルは、予測誤差損失と方向予測損失を最小限に抑えることを目的とした LSTM モデルで、LSTM の内部単位は 121 個です。明らかに、LSTM-FD と GAN-FD の主な違いは、敵対的な訓練の存在です。

4.4. 評価指標

各時点の各在庫について、特定のメソッドに基づいて次のタイム ポイントの予測が行われます。

テスト対象のタイム ポイントの合計数が;次の基準を使用して、異なるモデルのパフォーマンスを評価しました。

(1) 二乗平均平方相対誤差(RMSRE) RMSRE は、予測力または予測協定の指標として使用されます。低い RMSRE は、予測が実際のデータと一致することを示します（この記事で RMSE ではなく RMSRE を使用する理由は、RMSRE が 42 株の結果を一様に比較しやすいということです）。

(2) 方向予測精度 (DPA)どこ DPA は系列トレンドに関する精度の割合を測定します。高い DPA は、より多くの勝利の取引を約束します。

4.5. 結果

モデル更新サイクルが予測パフォーマンスに及ぼす影響を調べるには、 と を使用します。中国の株式市場では、日は 1 週間、2 週間、1 ヶ月、1 四半期を表します。

表 4 および表 5 は、RMSRE と DPA の平均値を異なる (,) 示しています。この数字は、GAN-FD とその関連メソッドが RMSRE と DPA の 3 つのベースライン方式よりも優れたパフォーマンスを発揮することを明確に示しています。このターゲットメソッド GAN-F は RMSRE の改善をいくらかもたらしめますが、DPA の 3 つのベースライン方式を上回るものではありません。GAN-F とは対照的に、GAN-D は DPA でより良い結果を達成するが、RMSRE で失敗した。LSTM-FD は、予測誤差損失とトレーニングの方向予測損失を組み合わせた結果を改善します。最後に、予測誤差損失、方向予測損失、および敵対的トレーニング(GAN-FD)の組み合わせにより、ほとんどのシナリオで最高の RMSRE と DPA を達成できます。

表 4

RMSRE の概要と異なる (M, N) 。これらの数値は、42 銘柄の平均値です。

表 5

DPA の概要と異なる (M, N) これらの数値は、42 銘柄の平均値です。

実験に対する異なる M, N の影響を見てみましょう。GAN-FD は、最大平均 DPA(0.6956)および最小平均 RMSRE(0.0079)を得る (M, N) が(20,5)である場合。RMSRE が小さく、DPA が高い場合、これらのメソッドはすべて 10 または 20 の場合よりも 5 の方が適切に動作することに注意してください。これは、非常に短期的な傾向が次の分の価格を予測するのに最適であることを意味します。したがって、より短いモデル更新サイクル(例えば、5)が好ましい。一方、同じに対して、異なる予測結果にいくつかの変更をもたらすでしょう。実験結果から、より大きい値をとるべきであることを示唆する。これは直感的に意味をなします。トレーニングサンプルが不十分な場合、特に不安定な株式市場では、モデルのトレーニングに失敗します。また、テストセットが大きい間にトレーニングセットが小さい場合(すなわち、 (M, N) , N が(10,20)である場合、これらの方法のほとんどは最悪の結果を示し、これらの方法の DPA はランダム推測(すなわち、50%)に勝るものではない。

表 6 は、42 銘柄に対する最小 RMSRE を達成するための各方法の回数を示しています。これら 3 つのベースライン方式の結果がすべてゼロであることに注目してください。関連する方法を持つ GAN-FD は、RMSRE のこれら 3 つのベースラインメソッドよりも明らかに優れています。一方、GAN-FD は最小 RMSRE を 246 回取得し、これら 378 のシナリオ(42 銘柄と 9 グループ(M, N))で 65.08%を占 M, N める。最高のパフォーマンスは、 (M, N) , N が(20,5)で、40 銘柄の最小 RMSRE が GAN-FD から来ているときに現れました。

表 6

最小 RMSRE に関する回数。

表 7 は、42 銘柄にわたって最大の DPA を達成する各方法の回数を示す。他の 6 つの方法と比較して、GAN-FD はすべてのシナリオで 71.16%を占め、最大 DPA 269 回を達成します。

$M(M,N)$ N が(10,5)の場合、42 株の最大 DPA は GAN-FD から来ます。 $M(M,N)$ N が(20,20)、つまりガン-FD ケースの最悪のパフォーマンスであっても、GAN-FD は 14 銘柄で最大の DPA を獲得します。上記の分析から、GAN-FD の性能は他の 6 つの方法よりも大幅に優れています。

表 7

最大 DPA に関する回数。

各表現の結果は、図 3~11 に報告されています。私たちは GAN-FD に焦点を当てています。図 3~5 に示すように 5、GAN-FD の DPA は 5 時に 64.59%~72.24%前後で、図 9~11 に示す 20%の 場合は 52.01%~62.71%まで落ち込 9~11 む。5 の場合、42 株にわたる GAN-FD の RMSRE は 0.48%から 1.49%の間で変動し、ほとんどの場合、他の 6 つの方法よりも低く、ボラティリティ は小さくなります。しかし、GAN-FD の RMSRE は劇的に増加し、20 であると激しく変動し、 1.21%から 4.96%の間で変化します。さらに、モデルの更新サイクルを短縮し、市場スタイルの 変化に適応するためにモデルパラメータを定期的に修正する必要があることを示しています。

図 3

DPA と RMSRE は、各在庫の (M, N) が $(10, 5)$ であり、-軸は株式 ID を表します。

図 4

DPA と RMSRE は、各在庫の (M, N) が $(20, 5)$ であり、-軸は株式 ID を表します。

図 5

DPA と RMSRE は、各在庫の (M, N) が $(60, 5)$ であり、-軸は株式 ID を表します。

図 6

DPA と RMSRE は、各在庫の (M, N) が $(10, 10)$ であり、-軸は株式 ID を表します。

図 7

DPA と RMSRE は、各在庫の (M, N) が $(20, 10)$ であり、-軸は株式 ID を表します。

図 8

DPA と RMSRE は、各在庫の (M, N) が $(60, 10)$ であり、-軸は株式 ID を表します。

図 9

DPA と RMSRE は、各株式の (M, N) が $(10, 20)$ であり、-軸は株式 ID を表します。

図 10

DPA と RMSRE は、各株式の (M, N) が $(20, 20)$ であり、-軸は株式 ID を表します。

図 11

DPA と RMSRE は、各株式の (M, N) が $(60, 20)$ であり、 x -軸は株式 ID を表します。

5. 結論

本稿では、より多くの非金融プロフェッショナルな一般投資家が意思決定を行う支援を行う、GAN-FD と呼ばれる使いやすい株式予測モデルを提案する。GAN-FD は、複雑な入力データの前処理を避けるために、入力データとして 13 の簡単な技術インデックスを採用しています。ディープラーニングネットワークに基づいて、このモデルは、敵対的なトレーニングによって他のベンチマーク法よりも優れた予測能力を達成し、方向予測損失を最小限に抑え、誤差損失を予測します。さらに、モデル更新サイクルが予測能力に及ぼす影響を分析し、実験結果は、より小さいモデル更新サイクルがより良い予測パフォーマンスを得ることができることを示しています。今後は、予測モデルをマルチスケール条件で統合していきます。

利益相反

著者らは、本論文の出版に関して利益相反はないと宣言している。

確認

この研究は、中国国家主要研究プログラム(2017YFB0802800)と中国国立自然科学財団(no. 61473149)によって支援されています。

参照

1. R. Al-Hmouz, W. Pedrycz, A. バラマッシュ, "時系列の説明と予測: 粒状コンピューティングの一般的なフレームワーク, アプリケーションを持つエキスパートシステム, vol. 42, no. 10, pp. 4830-4839, 2015.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
2. S. バラクと M. Modarres 「 データマイニング方式で効果的な特徴を予測して株式を評価するアプローチを開発する」 アプリケーションを使用したエキスパートシステム, vol. 42, no. 3, pp. 1325-1339, 2015.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
3. A. ブース、E.ゲルディング、F.マクグロアーティ 「パフォーマンス加重ランダムフォレストと季節性による自動取引」、 アプリケーション付きエキスパートシステム、 vol. 41、 no. 8、 pp. 3651-3661、 2014.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
4. バゲリ、H.モハマディ・ペイハニ、M・アクバリ 「量子行きの粒子群最適化を伴う ANFIS ネットワークを用いた財務予測」、 アプリケーションを備えたエキスパートシステム、 vol. 41、 no. 14、 pp. 6235-6250、 2014.View at [Publisher サイト](#) | [グーグルスカラー](#)
5. Y. ソン、D.-J.能と J.リー 「学習分類器を用いた高周波 KOSPI200 指数データの予測動向」、 アプリケーションを持つエキスパートシステム、 vol. 39、 no. 14、 pp. 11607-11615.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
6. I. オルドリッジと S.クラウチフ、高頻度取引における「リアルタイムリスク:投資家が FinTech について知っておくべきこと」、フラッシュクラッシュ、ジョン・ワイリー&サンズ社、ホーボークン、NJ、アメリカ、2017.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
7. F. A. デ・オリベイラ、C.N.ノブレ、L.E.サラテ、「株価の予測と方向性予測指数の改善に人工ニューラルネットワークを適用する - PETR4、ペトロブラス、ブラジルのケーススタディ」、アプリ

リケーションを持つエキスパートシステム、vol.40、no.18、pp. 7596-7606、2013.View

[Publisher Site](#) [グーグルスカラー](#)

8. J. H. Nio-Pea と G. J. ヘルナンデス・ペレス「深い信念ネットワークを用いた高周波データの価格方向予測」、コンピュータと情報科学のコミュニケーション、vol. 657, pp. 74-83, 2016.View at [出版](#)

[版社サイト](#) | [グーグルスカラー](#)

9. A. マルザウエクと T. ブルチンスキー「注文されたファジーローソク足による金融時系列のモデリングと予測」情報科学, vol. 273, pp. 144-155, 2014.View at: [パブリッシャーサイト](#) | [グーグルス](#)

[カラー](#) | [マスシネット](#)

10. X. Li, X. 黄, X. トウ, S. 朱, "市場のニュースと株価情報の両方を統合することにより、定量的な日中の株価予測を強化します,ニューロコンピューティング, vol. 142, pp. 228-238, 2014.View at:

[パブリッシャーサイト](#) | [グーグルスカラー](#)

11. X. Wang, S. Bao, J. 陳, "高周波ストックリンケージと多次元定置プロセス, *Physica A: 統計力学とそのアプリケーション*, vol. 468, pp. 70-83, 2017.View at: [パブリッシャーサイト](#) | [グーグルスカ](#)

[ラー](#) | [マスシネット](#)

12. E. チョン、C.ハン、F.C.パーク「株式市場分析と予測のためのディープラーニングネットワーク：方法論、データ表現、ケーススタディ」、アプリケーションを持つエキスパートシステム、vol.

83, pp. 187-205, 2017.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)

13. I. J. グッドフェロー, J. Pouget-Abadie, M. Mirza ら, "生成的敵対ネット" 第 28 回神経情報処理システムに関する年次会議の議事録に 2014, *NIPS 2014*, pp. 2672-2680, 2014 年 12 月, View,

[Google Scholar](#)

14. S. 飯塚, E. Simo-Serra, H. 石川, "グローバルかつローカルに一貫した画像補完", *グラフィックス上の ACM トランザクション*, vol. 36, 第 4, 記事第 107, 2017.ビューアット: [出版社サイト](#) | [グーグルスカラー](#)
15. P. リュック, C. クープリー, S. チンタラ, J. Verbeek, 敵対的なネットワークを使用した意味セグメンテーション, *arXiv preprint*, arXiv, 1611.08408, 2016, arXiv:1611.08408.
16. M. マチュー, C. クープリー, Y. LeCun, 平均平方誤差を超えた深いマルチスケールビデオ予測, *arXiv プリプリント*, arXiv, 1511.05440, 2015, arXiv:1511.05440.
17. J. D. ハミルトン, *時系列分析*, vol. 2, プリンストン大学出版局, 1994. View at: [MathSciNet](#)
18. R. H. S. Stoffer, *時系列分析とその用途*, 統計のスプリンガーテキスト, スプリンガー, ニューヨーク, ニューヨーク, アメリカ合衆国, 第 3 版, 2011. View at: [出版社サイト](#) | [マシネット](#)
19. P. J. ブロックウェルと R. デイビス, *Time シリーズ: 理論と方法*, スプリンガーサイエンス&ビジネスメディア, 2013 年。
20. S. ペレグリーニ, E. ルイス, A. エスパサ 「確率的成分を伴う条件付きヘテロセダスティック時系列の予測間隔」 *国際予測ジャーナル*, vol. 27, No. 2, pp. 308–319, 2011. View at [Publisher サイト](#) | [グーグルスカラー](#)
21. Y. Kara, M. Acar Boyacioglu, Ö. K. Baykan, 「人工ニューラルネットワークとサポートベクターマシンを使用した株価指数の動きの方向を予測する: イスタンブール証券取引所のサンプル」, *アプリケーションを持つエキスパートシステムズ*, vol. 38, no. 5, pp. 5311–5319, 2011. View at: [出版社サイト](#) | [グーグルスカラー](#)

22. M. Ghiassi, J. スキナー, D. ジンブラ, "Twitter ブランドの感情分析: n グラム分析とダイナミック人工ニューラルネットワークを使用したハイブリッドシステム, アプリケーションを持つエキスパートシステム, vol. 40, no. 16, pp. 6266-6282, 2013. View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
23. M. R. ハッサン, "株式市場予測のための隠されたマルコフモデルとファジーモデルの組み合わせ, ニューロコンピューティング, vol. 72, no. 16-18, pp. 3439-3446, 2009. View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
24. W. 黄, Y. ナカモリ, S.-Y. Wang, "サポートベクトルマシンで株式市場の動きの方向を予測する" コンピュータ&オペレーションリサーチ, vol. 32, no. 10, pp. 2513-2522, 2005. View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
25. A. F., S. エルサーと H. ファリス 「回帰、人工ニューラルネットワークと予測株式市場指数のためのサポートベクターマシンの比較」、人工知能の高度研究の国際ジャーナル、vol. 4, no. 7, 2015. View at: [出版社サイト](#) | [グーグルスカラー](#)
26. 進化計算に関する IEEE 会議の議事録(CEC '08)、pp.1276-1282、香港、香港、香港、6月20.8日の[サイト](#) | で「粒子群最適化技術を使用して S&P 500 と DJIA 株価指数の予測」を見る [グーグルスカラー](#)
27. S. S. アッパドゥー, ファジィ代数モデルを用いた金融デリバティブの価格設定: 理論的および計算的アプローチ [博士の研究], マニトバ大学, ウィニペグ, 2006.
28. A. タバネスワラン, K. チアガラジャ, S.S. アッパドゥー, 「ファジィ係数ボラティリティ ({FCV}) アプリケーション付きモデル」、数学およびコンピュータモデリング, vol. 45, no. 7-8, pp. 777-786, 2007. View at: [Publisher サイト](#) | [グーグルスカラー](#) | [マシネット](#)

29. C. カールソンと R. フラー, "ファジィ番号の確率的平均値と分散について" *ファジー集合体*, vol. 122, no. 2, pp. 315–326, 2001. View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
30. A. タバネスワラン、S.S.アパドゥー、A.パセカ、「{GARCH}モデリングとオプション価格へのアプリケーションを持つファジィ番号の加重確率的瞬間」、*数学とコンピュータモデリング*, vol.49、no.1-2、pp.352–368、2009. View at: [出版社サイト](#) | [グーグルスカラー](#) | [マスシネット](#)
31. N. スリヴァスタヴァ, G. ヒントン, A. クリシェフスキー, I. Sutskever, R. サラクッティノフ, "ドロップアウト: ニューラルネットワークのオーバーフィッティングを防ぐための簡単な方法, *ジャーナルオブ機械学習研究*, vol. 15, no. 1, pp. 1929-1958, 2014. View: [Google Scholar](#) [マスシネット](#)
32. A. M. むしろ、 A. A. A. A. A. A. A. A. A. A. A. A. A. Sastry, "繰り返しニューラルネットワークと株式リターンの予測のためのハイブリッドモデル" *アプリケーションを持つエキスパートシステム*, vol. 42, no. 6, pp. 3234–3241, 2015. View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
33. R. D. A. Araújo, A. L. I. オリベイラ, S. メイラ, "高頻度の株式市場予測のためのハイブリッドモデル" *アプリケーションを持つエキスパートシステム*, vol. 42, no. 8, pp. 4081-4096, 2015. View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
34. H. 陳、 K. Xiao、 J. Sun、 S. Wu 「高周波予測のための二層ニューラルネットワークフレームワーク」、 *管理情報システムに関する ACM トランザクション(TMIS)*, vol.7,no.4,記事第 11 条:[出版社サイト](#) | [グーグルスカラー](#)

35. A. 吉原、藤川 K、関、上原英「再発性深いニューラルネットワークによる株式市場動向予測」
PRICAI 2014 年:人工知能の動向、コンピュータサイエンスにおける講義ノート vol.759-769、スプリンガー・インターナショナル出版、Cham、2014.View [Publisher Site](#) [グーグルスカラー](#)
36. X. Ding, Y. 張, T. 劉, J. Duan, 「イベント主導の株式予測のためのディープラーニング」 第 24 回
人工知能に関する国際合同会議の議事録, *IJCAI 2015*, pp. 2327-2333, arg, 2015.View at: [Google Scholar](#)
37. Z. 周, J. 趙, K. 徐, 「オンライン感情は中国の株式市場を予測できるか」 *ウェブ情報システム工学国際会議紀要*, pp. 328-342, 2016.View at: [Google Scholar](#)
38. S. Hochreiter と J. Schmidhuber, "長期短期記憶, *神経計算*, vol. 9, no. 8, pp. 1735–1780, 1997.View at: [出版社サイト](#) | [グーグルスカラー](#)
39. Y. LeCun, L. Bottou, Y. ベンジオ, P. ハフナー, "ドキュメント認識に適用されるグラデーションベースの学習, *IEEE の議事録*, vol. 86, no. 11, pp. 2278–2323, 1998.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
40. A. アレバロ、J. ニオ、G. ヘルナンデス、J. サンドバル「ディープニューラルネットワークに基づく高周波取引戦略」 *インテリジェントコンピューティングに関する国際会議の議事録*, pp. 424-436、2016.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
41. K.-J. Kim, "サポートベクターマシンを用いた金融時系列予測" *ニューロコンピューティング*, vol. 55, no. 1-2, pp. 307–319, 2003.View at: [パブリッシャーサイト](#) | [グーグルスカラー](#)
42. S. マッジ、サポートベクターマシンを使用して株価方向を予測し、独立した作業レポート春、2015 年。

著作権

著作権 © 2018 年興友周らこれは、[クリエイティブ・コモンズ・アトリビューション・ライセンス](#)の下で配布されたオープン・アクセス・アーティクルで、オリジナルの作品が適切に引用されていれば、任意の媒体での無制限の使用、配布、および複製を許可します。